

1 基于强化学习的运动控制

四足机器人在月面巡视时会遇到坡面、台阶、沟槽、碎石等多种地形，地形之间切换频繁，单一步态或手工设计的控制器很难全部覆盖。本项目的腿部运动控制采用端到端的深度强化学习方法，在 PRISM 框架[1]的基础上，针对本机器人（12 个腿部关节，背负 RM75 机械臂）重新设计了观测接口、网络规模和训练配置。控制器直接以深度图像和本体感知为输入，输出 12 个腿部关节的目标位置，再由底层 PD 控制器转换为关节力矩。训练在 Isaac Gym 中进行[2,3]，算法为近端策略优化（PPO）[4]。

本章先介绍整体架构，然后按数据流的顺序依次说明视觉感知与融合模块、读写记忆估计器、混合专家策略网络和底层执行，最后介绍训练流程与部署推理方式。

1.1 整体架构

控制问题可以看作一个部分可观测马尔可夫决策过程：策略只能看到机载传感器提供的信息，地形高度、足端接触力、真实机身速度等量在实机上无法直接测量。为了在信息不完整的条件下做出合理决策，网络需要从历史观测和深度图像中把这些隐藏状态估计出来。基于这个思路，整个控制器分为三个部分，结构如图 1 所示。




图 1 强化学习运动控制器整体架构

第一部分是视觉感知与跨模态融合模块。深度图先经过卷积网络编码为一组局部视觉 token，再由主动采样从中挑出 16 个位置的特征；最近 10 帧本体观测经过 MLP 编码为 10 个本体 token。两类 token 连同视觉标志 token 一起送入 Transformer 融合，输出 10 个已经吸收了地形信息的本体特征 X_{t_0} 。

第二部分是读写记忆估计器，参考 PRISM 中 MATE-GRU[1]的思路实现。它一方面用运动 GRU 估计机身速度和足端高度，另一方面用 3 个读写记忆专家维护一个 64 维的共享状态 s_t ，用来记住机器人走过的地形。估计器最终输出 69 维的控制码 MCP_t 。

第三部分是混合专家策略网络。它把当前观测、控制码和视觉标志拼接成 115 维输入，由 8 个动作专家分别给出动作建议，再按门控权重加权得到最终动作 a_t 。训练时另有一个非对称 Critic 读取仿真中的特权信息，用来估计状态价值，部署时不需要它。

几个模块的运行频率不同。策略网络每 20 ms 执行一次（50 Hz），深度相机和估计器大约每 100 ms 刷新一次（10 Hz），估计器不刷新的周期里策略直接复用上一次的控制码。各模块的主要接口见表 1。

表 1 控制器主要输入输出

信号	维度	说明
当前本体观测 o_t	45	机身角速度 3、重力投影 3、速度指令 3、关节位置偏差 12、关节速度 12、上一动作 12
本体历史 O_t	10×45	最近 10 个控制周期的 o_t ，覆盖约 0.2 s
深度图 D_t	58×87	裁剪、缩放并归一化到[-0.5, 0.5]，约 10 Hz 更新
视觉标志 b_t	1	当前帧视觉是否可用
控制码 MCP_t	69	估计器输出，包括速度、足高、地形潜变量和地形类别
动作 a_t	12	12 个腿部关节的位置偏移量
特权观测 x_t^{priv}	269	仅训练时使用，含真实速度、接触力、高度采样等

动作 a_t 不直接作为力矩输出，而是叠加在默认站立姿态上形成目标关节角，再经 PD 控制得到力矩：

$$\dot{q}_t^{\text{c}} = \dot{q}_0 + 0.2 a_t, \tau = \text{clip}\left(K_p(q_t^{\text{c}} - q) - K_d \dot{q}, -\tau_{\max}, \tau_{\max}\right) \quad (1)$$

其中 q_0 为默认关节角，仿真中 $K_p=500$ 、 $K_d=18$ 。策略输出的目标角在一个控制周期内保持不变，PD 控制器则在每个 5 ms 的物理步内用最新反馈重新计算力矩。采用位置控制而不是直接输出力矩，可以让策略在较低频率下工作，也更容易迁移到实机伺服驱动上。

1.2 视觉感知与跨模态融合

这一模块的任务是从深度图中提取对落脚有用的局部几何信息，并与本体历史融合。它的内部结构如图 2 所示，输入为深度图 D_t 、本体历史 O_t 和视觉标志 b_t ，输出为融合本体特征 $X_t \in R^{10 \times 64}$ 。




图 2 视觉感知与跨模态融合模块结构

深度编码。 训练时的深度图由相机射线与地形网格求交得到，原始分辨率 60×106 ，经过裁剪和双线性缩放变为 58×87 ，有效距离截断在 $0 \sim 2$ m 后线性映射到 $[-0.5, 0.5]$ 。编码器由三层卷积组成（卷积核 3×3 ，步长 2，填充 1），特征图尺寸依次为 $16 \times 29 \times 44$ 、 $32 \times 15 \times 22$ 和 $64 \times 8 \times 11$ 。最后的 8×11 个空间位置各自对应一个 64 维 token，共 88 个，每个 token 描述深度图上一小块区域的几何形状。

局部重建约束。 为了让 token 确实保留局部几何，而不是只学到对奖励有用的捷径特征，训练时给每个 token 接一个局部解码器（ $64 \rightarrow 128 \rightarrow 225$ ），要求它重建对应位置 15×15 的深度块。深度块由 unfold 操作从原图上以步长 8 滑窗得到，正好也是 88 块。重建损失为

$$L_{\text{patch}} = \frac{1}{N} \sum_{i=1}^N \|\hat{q}_i - q_i\|_2^2 \quad (2)$$

其中 $\hat{q}_i$ 是第 i 个 token 的重建结果， q_i 是对应的真实深度块， $N=88$ 。这一项以 0.05 的权重加入估计器损失，解码器只在训练时使用。

主动采样。 88 个 token 全部送入 Transformer 计算量偏大，而且远处和边缘区域对落脚帮助不大。模块先对有效 token 取平均，由坐标 MLP 一次预测 16 个二维采样坐标（经 Sigmoid 限制在图像范围内），再用双线性插值（grid_sample）从 token 图上取出这 16 个位置的特征。采样坐标经过一个 $2 \rightarrow 64$ 的编码后加到特征上，让后面的网络知

道每个特征来自图像的哪个位置。采样点的位置随输入变化，网络可以根据当前地形把注意力放在前方台阶边缘或落脚区域上。

视觉失效时，有效掩码 m_t 会把对应位置屏蔽，采样到的有效权重过低的点在 Transformer 中按 padding 处理。训练时还会随机遮挡 token 图上 1~3 个空间连续的小块（比例 0~0.15），模拟深度相机在反光、强光或遮挡下的局部缺失；简单地形上视觉标志也会周期性关闭，强迫策略学会仅靠本体感知行走。

跨模态融合。本体历史中的每一帧经过本体 MLP（45→64）得到一个 token，视觉标志 b_t 嵌入为一个 token，加上 16 个视觉 token，共 27 个 64 维 token。每个 token 再加上位置、时间和模态编码后送入一层 Transformer 编码器[5]（4 头注意力，每头 16 维，前馈层 64→256→64），核心运算是缩放点积注意力：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3)$$

经过自注意力，本体 token 可以按需要从视觉 token 中读取地形信息。下游只取输出中对应 10 个本体位置的 token 作为 X_t 。

1.3 读写记忆估计器（MATE-GRU）

X_t 只包含最近约 0.2 s 的信息，而机器人通过一段地形往往需要几秒钟，相机也看不到已经走到机身下方的区域。读写记忆估计器的作用就是在较长时间尺度上积累地形信息，并把各种估计量整理成策略能直接使用的控制码。模块结构如图 3 所示，输入为 X_t 、当前观测 o_t 、视觉标志 b_t 和上一时刻的共享状态 s_{t-1} ，输出为控制码 MCP_t 和新的共享状态 s_t 。




图3 读写记忆估计器 (MATE-GRU) 结构

模块内部有两条相对独立的支路。上方的运动分支用一个 GRU 依次读入 10 个融合本体特征，取最后的隐藏状态 h_t^m ，经运动预测头输出机身线速度估计 $\hat{v}_t$ (3 维) 和四足离地高度估计 $\hat{h}_t^f$ (4 维)。这条支路每次只看当前的 10 步窗口，不跨估计周期保存状态。下方的记忆支路负责地形相关的长时信息，是本模块的核心。

注意力池化与专家路由。记忆支路首先用可学习的查询向量对 10 个本体特征做注意力池化：

$$\alpha_{k,j} = \text{softmax}_j(q_k^T x_j), p_k = \sum_{j=1}^{10} \alpha_{k,j} x_j \quad (4)$$

其中 x_j 为 X_t 的第 j 个 token。共享查询 q_0 得到的 p_0 送入三个头：地形分类头输出 13 类地形概率 c_t ，恢复判别头输出机器人是否处于跌倒恢复状态的概率 r_t ，上下文头输出 64 维上下文特征。随后 c_t 和 r_t 各自经过两组编码器，一组 (64 维) 加到专家特征上，另一组 (32 维和 16 维) 与当前观测、视觉标志和上下文特征拼接成 158 维向量，送入路由 MLP 得到 3 个记忆专家的权重：

$$g_t = \text{softmax} \left(F_g \left(\left[o_t, b_t, f_t^{\text{ctx}}, \phi_c(c_t), \phi_r(r_t) \right] \right) \right) \quad (5)$$

路由同时用到了当前观测和地形判断，因此专家权重会随地形和运动状态连续变化。训练中没有人为规定哪个专家负责哪种地形，分工完全由数据驱动形成。

读写记忆专家。每个专家 i 有自己的查询向量 q_i ，池化后加上地形和恢复编码，得到专家输入 $e_{t,i}$ 。专家内部依次执行“读—更新—写”三步：读 MLP 把共享状态映射为 GRUCell 的初始隐藏状态，GRUCell[6]用 $e_{t,i}$ 更新它，写 MLP 再根据更新后的隐藏状态给出对共享状态的修改量：

$$h_{t,i} = \text{GRUCell}(e_{t,i}, R_i(s_{t-1})), \Delta_{t,i} = W_i(h_{t,i}) \quad (6)$$

三个专家参数互不共享，但读写的是同一个共享状态。与 PRISM 原文为每个专家单独设计门控的做法相比，这种结构把“记忆”集中在一个向量里，专家只负责提出修改意见，状态不会因专家权重切换而突然跳变。

共享状态更新。各专家的隐藏状态和修改量按路由权重加权，得到 $\tilde{h}_t = \sum_i g_{t,i} h_{t,i}$ 和 $\tilde{\Delta}_t = \sum_i g_{t,i} \Delta_{t,i}$ 。共享状态的更新采用门控写入加层归一化：

$$u_t = \sigma(F_u([s_{t-1}, \tilde{\Delta}_t])), s_t = \text{LN}(u_t \odot F_c([s_{t-1}, \tilde{\Delta}_t]) + (1 - u_t) \odot s_{t-1}) \quad (7)$$

写入门 u_t 逐维决定保留多少旧记忆，初始化时其偏置设为 -2，使网络在训练初期倾向于保留旧状态。层归一化用来限制状态幅值，避免长时间运行后数值漂移。 s_t 在下一个估计周期作为 s_{t-1} 输入，每个回合开始或机器人复位时清零。

控制码输出。 $\tilde{h}_t$ 与 s_t 拼接后送入地形预测头，得到 16 维地形潜变量均值 z_t^μ 和 32 维局部地图潜变量 z_t^{tm} 。最终控制码为

$$\text{MCP}_t = [\hat{v}_t, \hat{h}_t^f, z_t^\mu, z_t^{\text{tm}}, \text{onehot}(\arg \max c_t), 1[r_t \geq 0.5]] \in R^{69} \quad (8)$$

其中地形类别和恢复状态以离散形式进入控制码，连续的概率值只在估计器内部用于路由。控制码在送入策略网络之前截断梯度，也就是说 PPO 的梯度不会回传到估计器，估计器完全由下面的监督目标训练。

1.4 估计器的训练目标

如果只用策略梯度训练估计器，中间变量的含义很难保证，训练也不稳定。因此估计器配有一组辅助解码头和监督目标，全部真值都来自仿真器，部署时这些解码头可以去掉。总损失为

$$L_{\text{est}} = L_v + L_h + L_{\text{map}} + 0.5(L_{\text{obs}}^m + L_{\text{obs}}^t) + L_{\text{CE}} + L_{\text{BCE}} + 0.05 L_{\text{patch}} + \beta L_{\text{KL}} + \lambda L_{\text{SwAV}} \quad (9)$$

各项的含义见表 2。其中 L_{map} 要求 z_t^{tm} 经解码器 ($32 \rightarrow 64 \rightarrow 187$) 重建机器人周围 187 个点的高度采样，这一项是 z_t^{tm} 成为“局部地图编码”的主要原因；两个下一观测预

测项要求网络能预测执行动作后一个控制周期的本体观测，相当于让估计器学习一个简单的前向模型。SwAV 项[7]将 3 维专家门控窗口与特权地形高度窗口投影到同一个 32 维空间，用 16 个原型做交换聚类，使专家路由与真实地形结构对应起来。

表 2 估计器监督目标

损失项	监督信号	权重
L_v, L_h	真实机身速度、足端高度 (MSE)	1
L_{map}	187 点地形高度采样 (MSE)	1
$L_{\text{obs}}^m, L_{\text{obs}}^t$	下一控制周期的本体观测 (MSE)	各 0.5
$L_{\text{CE}}, L_{\text{BCE}}$	地形类别标签、恢复状态标签	1
L_{patch}	局部深度块重建 (MSE)	0.05
L_{KL}	地形潜变量的标准正态先验	$0 \rightarrow 0.01$
L_{SwAV}	门控与特权地形的聚类一致性	$0 \rightarrow 0.02$

KL 项和 SwAV 项都采用逐步增大的权重。KL 权重从 0 开始线性增加到 0.01；SwAV 从第 2000 次估计器更新开始启用，在随后 8000 次更新内增加到 0.02。这样做是为了让网络先学会基本的状态估计，再施加正则。估计器使用单独的 Adam 优化器，学习率 1×10^{-3} ，在每次估计器刷新后立即更新。

1.5 混合专家策略网络与非对称 Critic

策略网络把估计器给出的控制码转换为关节动作。不同地形需要的步态差别较大，例如上台阶要求抬腿高、走窄桥要求步宽小，用一个普通 MLP 同时拟合容易互相干扰，因此这里采用软路由的混合专家结构，如图 4 所示。




图 4 混合专家 Actor 与非对称 Critic 结构

Actor。 输入 $x_t^{\text{actor}} = [o_t, MCP_t, b_t] \in R^{115}$ 。共享 MLP (115 → 512 → 256 → 1024) 一次输出 1024 维特征，按通道重排为 8×128，再用 8 组的分组一维卷积把每组 128 维映射

为 12 维，得到 8 个专家各自的动作建议 $A_i(x)$ 。这种写法在计算上等价于 8 个小型专家头，但只需一次矩阵运算。另一个门控 MLP 根据同样的输入给出 8 个专家的权重，最终动作均值为

$$\mu_t = \sum_{i=1}^8 \rho_{t,i} A_i(x_t^{\text{actor}}), \rho_t = \text{softmax}(F_\rho(x_t^{\text{actor}})) \quad (10)$$

训练时动作服从以 μ_t 为均值的对角高斯分布，12 个标准差为独立的可学习参数；部署时直接取 $a_t = \mu_t$ ，不再采样。

软路由的一个常见问题是门控坍缩到少数几个专家上，其余专家得不到训练。为此在 PPO 损失中加入批次级负载均衡项[8]：

$$\dot{\rho}_e = \frac{1}{B} \sum_{b=1}^B \rho_{b,e}, L_{\text{lb}} = \frac{1}{8} \sum_{e=1}^8 (\dot{\rho}_e - \frac{1}{8})^2 \quad (11)$$

它只约束一个批次内各专家的平均使用率，单个时刻仍允许门控明显偏向某几个专家。该项权重为 0.01。

Critic。 Critic 采用非对称设计[9]，输入为 269 维特权观测加视觉标志共 270 维，包括真实线速度、角速度、关节状态、四足接触力、关节力矩、187 点地形高度、四足离地高度、地形编号和恢复标志等。这些量在仿真里可以直接读取，让 Critic 看到更完整的状态，价值估计会更准确，从而降低优势估计的方差。Critic 同样由共享 MLP 和分组卷积构成 8 个价值专家，加权所用的权重 ρ_t 由 Actor 门控在 Actor 输入上重新计算，两者的专家划分保持一致。Critic 只参与训练，导出部署模型时不包含这一部分。

1.6 奖励设计与训练设置

奖励函数。总奖励是若干奖励项的加权和，各项权重在初始化时乘以控制周期 0.02 s。按作用可以分为四类，主要项及其权重列于表 3。速度跟踪项是正向激励的主体；稳定性和能耗项约束机身姿态、关节力矩与动作平滑程度；地形通行项只在特定地形上生效，例如窄桥上的步宽奖励、台阶上前后足的支撑转移奖励，以及根据前方地形扫描结果计算的目标落脚点奖励。

表 3 主要奖励项

类别	奖励项（权重）
速度跟踪	线速度跟踪（1.0）、角速度跟踪（0.5）、平地前进速度（1.0）、有指令时低速惩罚（-0.5）
姿态稳定	机身高度（-1.5）、竖直速度（-2.0）、横滚俯仰角速度（-0.05）、碰撞（-1.5）、静止站

类别	奖励项 (权重)
驱动与平滑	立 (-0.5)
	关节力矩 (-2e-6)、关节功率 (-2e-5)、关节加速度 (-1e-8)、动作变化率 (-0.008)、动作平滑 (-0.008)、关节限位 (-2.0)
地形通行	目标落脚 (0.5)、抬脚净空 (0.5)、窄桥步宽 (0.5)、台阶先导足触高 (0.6)、支撑转移 (0.8)、后足跟随 (1.0)

地形课程与域随机化。训练地形由 10 个难度等级、13 类地形组成，包括平地、坡面、台阶、窄桥、沟槽和碎石等，每块地形 12 m×5 m。训练开始时最高难度为 2 级，回合结束时根据机器人前进的距离调整等级：走过半块地形（约 6 m）则升一级，距离明显不足则降一级。为了缩小仿真与实机之间的差距，训练时对动力学参数做了随机化，范围见表 4。

表 4 域随机化范围

参数	范围	参数	范围
地面摩擦系数	0 ~ 2	恢复系数	0 ~ 0.5
机身附加质量	±4 kg	连杆质量系数	0.95 ~ 1.05
质心偏移	±0.02 m	PD 增益系数	0.85 ~ 1.15
电机强度系数	0.9 ~ 1.1	关节零位偏差	±0.035 rad

训练参数。主要超参数见表 5。

表 5 主要训练参数

参数	取值	参数	取值
并行环境数	4096	回合时长	20 s
物理步长 / 控制周期	5 ms / 20 ms	每次迭代采样步数	24
PPO 学习率	2e-4 (自适应)	折扣因子 γ	0.99
GAE 参数 λ	0.95	裁剪系数 ϵ	0.2
熵系数	0.01	每次迭代更新	5 轮×4 个小批量
估计器学习率	1e-3	训练迭代次数	30000

1.7 训练流程

训练中有两套参数分别更新：Actor 和 Critic 由 PPO 更新，估计器由 1.4 节的监督损失通过独立的 Adam 优化器更新。两者在时间上交错进行，一次迭代的流程如图 5(a) 所示。




图 5 训练迭代流程与部署推理时序

每次迭代中，4096 个环境各自推进 24 个控制周期。在每个控制周期里，如果当前步是深度刷新步（每 5 步一次），估计器先做一次前向，更新控制码和共享状态；Actor 根据当前观测和缓存的控制码采样动作，Critic 同时给出价值估计；环境执行动作并推进 4 个物理步，返回新的观测、奖励和终止信号。在刷新步上，环境返回的新观测恰好可以作为估计器“下一观测预测”的监督目标，于是此时计算估计器损失并更新一次参数。某个环境回合结束时，对应的历史缓存和共享状态一起清零。

24 步采样结束后共得到 98304 条样本。先用 Critic 对最后一个状态的价值做自举，按广义优势估计[10]计算每一步的优势：

$$\delta_t = r_t + \gamma(1 - d_t)V(s_{t+1}) - V(s_t), \hat{A}_t = \delta_t + \gamma\lambda(1 - d_t)\hat{A}_{t+1} \quad (12)$$

其中 d_t 为终止标志。因超时而结束的回合不是真正的失败，实现中把 γV 加回到该步奖励上，避免把超时当作终止状态。优势在整批样本上做标准化后，进行 5 轮、每轮 4 个小批量的 PPO 更新，损失为

$$L = -E_t \left[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t) \right] + L_{\text{value}} - 0.01 H(\pi_\theta) + 0.01 L_{\text{lb}} \quad (13)$$

其中 $r_t(\theta) = \pi_\theta(a_t/x_t)/\pi_{\theta_{\text{old}}}(a_t/x_t)$ 为新旧策略的概率比，价值损失 L_{value} 采用裁剪形式， H 为策略熵。梯度范数裁剪到 1，学习率根据新旧策略的 KL 散度自适应调整。整个训练共进行 30000 次迭代，每 100 次迭代保存一次模型。

1.8 推理与部署

部署时只保留前向计算和状态管理：Critic、奖励计算、各类辅助解码器和优化器都不再运行，动作也不采样，直接使用均值。推理按图 5(b)的双频率方式组织。估计器约每 100 ms 在新深度帧到达时运行一次，更新控制码和共享状态；Actor 每 20 ms 运

行一次，用最新的本体观测和缓存的控制码计算动作。两次估计器刷新之间，策略仍然能对机身姿态和关节状态的变化做出及时反应。

模型导出为两个 ONNX 网络，接口见表 6。导出时共享状态 s 改为显式的输入和输出，由部署程序在每次估计器调用后把 s_{next} 写回，下一次再作为输入传入；如果每次都传零，网络就失去了跨周期的记忆。机器人启动、重新接入或回合重置时，需要同时清空本体历史、共享状态和控制码缓存。

表 6 部署模型接口

模型	输入	输出	运行频率
估计器	本体历史 450、深度图 1×58×87、视觉标志 1、当前观测 45、共享状态 64	控制码 70（含标志位）、新共享状态 64	约 10 Hz
策略网络	控制码 70、当前观测 45	关节动作 12	50 Hz

在实际部署中，建议把快循环（本体观测与 Actor）和慢循环（深度处理与估计器）放在不同线程，用带时间戳的双缓冲交换控制码，避免估计器计算时阻塞 20 ms 的控制周期。

网络本身的计算量不大。按批大小为 1 估算，估计器一次完整前向约 9.1 M 次乘加，去掉只在训练时使用的解码分支后约 5.8 M 次；Actor 一次前向约 0.66 M 次乘加，8 个专家全部参与计算。参数量方面，估计器约 0.45 M，Actor 约 0.66 M，两者 FP32 权重合计约 4.4 MB。按估计器 10 Hz、Actor 50 Hz 计算，总计算需求约 0.25 GFLOP/s，对机载嵌入式计算平台来说负担较小，实时性主要取决于深度图预处理、数据传输和线程调度等环节。

参考文献

[1] PRISM: Resilient Quadruped Parkour under Impaired Sensing and Motion Constraints.

[2] Makoviychuk V, Wawrzyniak L, Guo Y, et al. Isaac Gym: High performance GPU-based physics simulation for robot learning[C]. NeurIPS Datasets and Benchmarks, 2021.

[3] Rudin N, Hoeller D, Reist P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning[C]. Conference on Robot Learning, 2022: 91-100.

[4] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[5] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems, 2017.

- [6] Cho K, van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]. EMNLP, 2014.
- [7] Caron M, Misra I, Mairal J, et al. Unsupervised learning of visual features by contrasting cluster assignments[C]. Advances in Neural Information Processing Systems, 2020.
- [8] Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer[C]. ICLR, 2017.
- [9] Pinto L, Andrychowicz M, Welinder P, et al. Asymmetric actor critic for image-based robot learning[C]. Robotics: Science and Systems, 2018.
- [10] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[C]. ICLR, 2016.